MAD 2022-23, Assignment 1

Helga Rykov Ibsen <
mcv462> Hold 6 $1.\ {\rm september}\ 2023$

Opgave 1

(a)

Vi er givet funktionen:

$$f(x,y) = x^4 y^3 + x^5 - e^y$$

Vi finder de partielle afledede af f mht. x og y som:

$$\frac{\partial f}{\partial x} = 4x^3y^3 + 5x^4$$
$$\frac{\partial f}{\partial y} = 3x^4y^2 - e^y$$

(b)

Vi er givet funktionen:

$$f(x,y) = \frac{1}{\sqrt{x^3 + x \cdot y + y^2}}$$

Vi finder de partielle afledede af f mht. x ved at bruge kedereglen som:

$$\frac{\partial f}{\partial x} = -\frac{\frac{1}{2\sqrt{x^3 + x \cdot y + y^2}} \cdot (3x^2 + y)}{(\sqrt{x^3 + x \cdot y + y^2})^2}$$
$$= -\frac{3x^2 + y}{2\sqrt{x^3 + x \cdot y + y^2} \cdot (x^3 + x \cdot y + y^2)}$$

Vi finder de partielle afledede af f mht. y ved at bruge kedereglen som:

$$\frac{\partial f}{\partial y} = -\frac{\frac{1}{2\sqrt{(x^3 + x \cdot y + y^2)}} \cdot (x + 2y)}{(\sqrt{x^3 + x \cdot y + y^2})^2}$$
$$= -\frac{x + 2y}{2\sqrt{x^3 + x \cdot y + y^2} \cdot (x^3 + x \cdot y + y^2)}$$

Vi er givet funktionen:

$$f(x,y) = \frac{x^3 + y^2}{x + y}$$

Vi finder de partielle afledede af f mht. x ved at bruge brøkreglen for differentiation som:

$$\frac{\partial f}{\partial x} = \frac{(x+y) \cdot (x^3 + y^2)' - (x^3 + y^2) \cdot (x+y)'}{(x+y)^2}$$
$$= \frac{3x^2(x+y) - (x^3 + y^2)}{(x+y)^2}$$

Vi finder de partielle afledede af f mht. y som:

$$\frac{\partial f}{\partial y} = \frac{(x+y) \cdot (x^3 + y^2)' - (x^3 + y^2) \cdot (x+y)'}{(x+y)^2}$$
$$= \frac{2y(x+y) - (x^3 + y^2)}{(x+y)^2}$$

Opgave 2

(a)

Vi er givet funktionen:

$$f(\overline{x}) = \overline{x}^T \cdot \overline{x} + c$$

Vi anvender tabellen (s.23 i bogen) og finder gradienten for f mht. \overline{x} som følger:

$$\frac{\partial f}{\partial \overline{x}} = 2\overline{x}$$

(b)

Vi er givet funktionen:

$$f(\overline{x}) = \overline{x}^T \cdot \overline{b}$$

Vi anvender tabellen (s.23 i bogen) og finder gradienten for f mht. \overline{x} som følger:

$$\frac{\partial f}{\partial \overline{x}} = \overline{b}$$

Vi er givet funktionen:

$$f(\overline{x}) = \overline{x}^T \cdot A\overline{x} + \overline{b}^T \cdot \overline{x} + c$$

Vi anvender tabellen (s.23 i bogen) og finder gradienten for f mht. \overline{x} som følger:

 $\frac{\partial f}{\partial \overline{x}} = 2A\overline{x} + \overline{b}$

Opgave 3

(a)


Mean of the house prices: 23

Figur 1: The mean of the house prices

(b)

RMSE: 9

Figur 2: The value of the RMSE



Figur 3: The 2D scatter plot

Opgave 4

(b)

```
Model coefficients (1.feature): [[23.63506195] [-0.43279318]]
```

Figur 4: Weights w_0 and w_1

De to koefficienter fortæller os om hvordan modellen/udviklingen ser ud grafisk. Den første konstante koefficient w_0 fortæller os om hvor den rette linje kommer til at ligge ift.y-aksen (ca. 23) og den anden konstante koefficient w_1 fortæller os at den rette linje kommer til at gå i faldende/nedadgående retning fordi den er negativ.


```
Model coefficients (all feature):
    [[ 1.95123661e+01]
    [-6.65962795e-02]
    [ 1.65961371e-02]
    [-5.18606201e-02]
    [ 2.82306875e+00]
    [-2.14548721e+01]
    [ 6.09191498e+00]
    [-4.38038546e-02]
    [-1.42409460e+00]
    [ 2.87670030e-01]
    [-1.39327428e-02]
    [-9.33505242e-01]
    [ 1.54948728e-02]]
```

Figur 5: Weights w_i

(d)

```
The value of the loss function for the first feature: 7
The value of the loss function for all features: 5
```

Figur 6: The value of the RMSE



Figur 7: The 2D scatter plots of the model based on the first feature (a) and all features (b)

Opgave 5

Vi skal finde de optimale estimater \hat{w}_0 og \hat{w}_1 for den totale training funktion \mathcal{L} :

$$\mathcal{L} = \sum_{n=1}^{N} (f(\mathbf{x}_n; \mathbf{w}) - t_n)^2 = \sum_{n=1}^{N} (\mathbf{w}^T \mathbf{x}_n - t_n)^2$$

Vi starter med at omskrive det første led i parentesen i det sidste udtryk på formen af ligningen for den rette linje:

$$\mathcal{L} = \sum_{n=1}^{N} (\mathbf{w}^{T} \mathbf{x}_{n} - t_{n})^{2}$$

$$= \sum_{n=1}^{N} (w_{0} + w_{1}x_{n} - t_{n})^{2}$$

$$= \sum_{n=1}^{N} (w_{0}^{2} + w_{1}^{2}x_{n}^{2} + t_{n}^{2} + 2w_{0}w_{1}x_{n} - 2w_{1}t_{n}x_{n} - 2w_{0}t_{n})$$

Vi skal nu differentiere udtrykket mht. variablerne \hat{w}_0 og \hat{w}_1 :

$$\frac{\partial \mathcal{L}}{\partial w_0} = \sum_{n=1}^{N} (2w_0 + 2w_1 x_n - 2t_n)$$

$$\frac{\partial \mathcal{L}}{\partial w_1} = \sum_{n=1}^{N} (2w_1 x_n^2 + 2w_0 x_n - 2t_n x_n)$$

Nu skal vi løse ligningssystemet for \hat{w}_0 og \hat{w}_1 . Vi sætter de to ligninger lige med 0, smider det sidste led på den anden side af lighedstegnet og dividerer med 2 på begge sider:

$$\sum_{n=1}^{N} w_0 + \sum_{n=1}^{N} w_1 x_n = \sum_{n=1}^{N} t_n$$
$$\sum_{n=1}^{N} w_1 x_n^2 + \sum_{n=1}^{N} w_0 x_n = \sum_{n=1}^{N} t_n x_n$$

Da summen af elementerne x er det sammen som at gange antallet af elementer N med gennemsnittet \overline{x} kan vi omskrive de to ligninger (n er gemt i gennemsnittet og kan også bortforkortes) som :

$$Nw_0 + w_1 N\overline{x} = N\overline{t}$$
$$w_1 N\overline{x^2} + w_0 N\overline{x} = N\overline{tx}$$

Da N optræder alle steder kan den også bortforkortes:

$$w_0 + w_1 \overline{x} = \overline{t}$$
$$w_1 \overline{x^2} + w_0 \overline{x} = \overline{tx}$$

Nu starter med at isolere w_0 i den første ligning og bestemme udtrykket for det første optimale estimatet \hat{w}_0 :

$$\hat{w}_0 = \overline{t} - w_1 \overline{x}$$

For at finde estimatet \hat{w}_1 indsætter vi det fundne \hat{w}_0 :

$$w_1 \overline{x^2} + (\overline{t} - w_1 \overline{x}) \overline{x} = \overline{tx}$$

$$w_1 \overline{x^2} + \overline{t} \overline{x} - w_1 \overline{x}^2 = \overline{tx}$$

$$w_1 (\overline{x^2} - \overline{x}^2) = \overline{tx} - \overline{t} \overline{x}$$

$$w_1 = \frac{\overline{tx} - \overline{tx}}{\overline{x^2} - \overline{x}^2}$$

Vi kan hermed se at de fundne estimater for den totale $loss\ training$ funktion er de samme som for den gennemsnitlige en (se bogen s.26). Det forventede vi også, fordi når vi skal finde parametrene som optimerer loss, så er det lige meget om vi bruger gennemsnittet af x'erne og t'erne eller totalt antal af dem.